

Vous n'avez pas de machine pour cet exercice.
En lancer une peut prendre un certain temps.

Lancer la
machine



Examen bloc 2 du titre RNCP Data Engineer — Projet ETL & ML

Le passage d'examen

L'examen est minuté et dure **4 heures**. Vous serez surveillé par un système qui s'appelle Méréos, que vous pourrez installer en suivant le tutoriel sur les slides. L'utilisation de [Google Chrome](#) est obligatoire pour la bonne exécution du système de surveillance. En cliquant sur le bouton **Valider** présent en bas de la page, vous débloquentez dans la section **Mes Exams** la possibilité de passer l'examen.

Voici les slides qu'il est **OBLIGATOIRE** de consulter avant de commencer l'examen:

[CONSIGNE SURVEILLANCE ÉVALUATION](#)

Vous allez uploader directement votre archive sur la page du sujet de l'examen, tout en bas du sujet.

Attention: pour utiliser la machine virtuelle de Datascientest, il faudra utiliser celle présente sur ce notebook donc démarrez la avant de commencer l'examen. Il s'agit de la même machine que pour le Bloc 2 donc si elle n'est pas vide, pensez à tout supprimer (fichiers, dossiers, containers docker etc) pour repartir sur un environnement vierge.

Les sujets abordés

Afin de vous préparer au mieux pour le passage de cet examen, voici les sujets qui seront abordés :

1. L'exploration de données au format JSON à l'aide de notebooks Jupyter.
2. Le développement de scripts Python structurés et réutilisables.
3. La manipulation de données avec les librairies [pandas](#) et [matplotlib](#).
4. La gestion des valeurs manquantes et des colonnes catégorielles.
5. La création d'une base de données relationnelle avec [Docker](#) et son administration via [phpMyAdmin](#).
6. L'utilisation de variables d'environnement dans les fichiers Docker ([.env](#)) et les scripts Python.
7. L'architecture de bases de données relationnelles (schéma logique, clés primaires et étrangères).
8. L'interfaçage avec une base de données SQL via [SQLAlchemy](#) et l'ORM. Concernant l'ORM, vous avez des ressources disponibles dans le notebook suivant.
9. L'entraînement d'un modèle de machine learning avec [scikit-learn](#).
10. L'évaluation et la sauvegarde d'un modèle ML avec [joblib](#).
11. La mise en place d'un environnement de production pour de la collecte et ingestion de données via [docker-compose](#).
12. L'écriture de tests robustes pour garantir la fiabilité de l'ingestion (gestion des erreurs, détection de doublons, conformité au schéma).
13. L'estimation de l'impact écologique d'un projet data (calcul de consommation énergétique), simple recherche Google.

Préparation de vos outils

Docker

Installez Docker sur votre machine ou utilisez la machine virtuelle mise à disposition. Assurez-vous de savoir :

- Lancer des conteneurs via [docker run](#).
- Créer et exécuter un fichier [docker-compose.yml](#).
- Monter des volumes pour la persistance des données ([volumes](#)).
- Configurer des variables d'environnement pour sécuriser vos services.

Python

Créez un environnement virtuel et installez les librairies nécessaires ([pandas](#), [sqlalchemy](#), [scikit-learn](#), [joblib](#), [matplotlib](#), etc.). Pensez à documenter et commenter votre code pour en faciliter la lecture.

Organisation

Votre rendu devra contenir :

- Un notebook d'exploration de données.
- Un script Python reprenant les étapes d'extraction et transformation.
- Un script de création de base de données (via ORM).
- Un script d'ingestion dans la base.
- Un script d'entraînement du modèle ML.
- Un fichier synthétique expliquant votre architecture, les choix techniques, et les pistes d'amélioration.



Cours terminé ?

✓ Marquer comme terminé

→ Exercice suivant
ORM

